NOC Agent — Modelos de IA: comparativa y costos

Informe técnico para el cliente · 12 de octubre de 2026 · Piloto Etapa 1 (solo lectura)

1. Resumen ejecutivo

> El piloto completo (consultas diarias + vigilancia automática cada 15 minutos) funciona con el plan **gratuito** usando el modelo **GPT OSS 120B**, que fue el de mejor desempeño en las pruebas (6 de 8 tareas correctas). Costo del piloto: **u$d 0**. Los modelos pagos solo aparecen como camino de crecimiento: a los volúmenes estimados costarían entre **u$d 1 y u$d 2 por mes** con los modelos recomendados, y solo se justifican si el uso supera el cupo gratuito.

2. Cómo funciona el servicio (gratis vs. pago)

El proveedor (Groq) ofrece los **mismos modelos en dos planes**:

- **Gratis:** sin tarjeta, con un cupo diario de uso (para el modelo elegido: 1.000 consultas y 200.000 fragmentos de texto por día). Verificado en la consola de la cuenta el 12/10/2026.
- **Pago:** mismos modelos, cupo ~10 veces mayor, se paga solo por lo consumido (desde u$d 1 acumulado, sin suscripción).

Dicho de otro modo: el plan gratuito incluye una cuota diaria de uso sin costo; superada esa cuota, cada unidad adicional se factura a precio de costo, sin abonos ni mínimos. **Nada de lo medido en este informe generó cargo alguno.**

3. Tabla comparativa — modelos gratuitos

Modelo	Cupo gratis/día	Prueba (8 tareas)	A favor	En contra
GPT OSS 120B (recomendado)	1.000 consultas 200.000 textos	**6/8**	El más preciso: resolvió investigaciones que los demás no pudieron. Respuestas ordenadas, con datos reales.	Las tareas muy extensas consecutivas pueden requerir algunos segundos de espera (se compensa con pausas y reintentos automáticos).

Qwen 32B (reserva)	1.000 consultas 200.000 textos	3–4/8	Buen desempeño en resúmenes simples. Alternativa de respaldo ante indisponibilidad del modelo principal.	Presenta limitaciones en investigaciones paso a paso (no sigue el procedimiento).
GPT OSS 20B	1.000 consultas 200.000 textos	5/8	Mayor velocidad de respuesta. Buen desempeño en investigación.	En ocasiones repite la misma consulta en lugar de variar la estrategia; respuestas extensas (mayor consumo). Segunda opción.
Allam 7B	7.000 consultas 500.000 textos	**0/8 útiles**	Cupo diario superior.	No sigue instrucciones: repite acciones y responde con generalidades sin datos concretos. **Descartado.**

4. Qué se probó (números)

- **Verificación básica del sistema (3/3):** conexión, lista de problemas activos, historial de un equipo y bloqueo correcto de una acción prohibida.
- **8 tareas reales por modelo** (resumir problemas, investigar un equipo, explicar por qué se disparó una alarma, traer valores): resumen simple ≈ 1.300 textos; investigación completa ≈ 2.000–6.000.
- **Prueba de exigencia (10 consultas seguidas sin pausa):** 8 fueron limitadas por velocidad. Con 60 segundos entre consultas: 5/5 correctas. Conclusión: el límite es de *velocidad por minuto*, no de cantidad diaria — el diseño final incluye pausas y reintentos automáticos.

5. El piloto entra en el plan gratuito (verificación)

Uso del piloto	Consumo/día	Cupo gratis	Margen
10 consultas de técnicos	~27.000 textos, ~30 consultas	200.000 / 1.000	**sobra**
Vigilancia cada 15 min	~125.000 textos, ~200 consultas	200.000 / 1.000	**entra**
Total piloto	**~150.000 / ~230**	200.000 / 1.000	**cubierto**

Los volúmenes de uso son supuestos a validar en operación.

6. Modelos pagos: solo como crecimiento

Si el uso creciera (más equipos, vigilancia cada 5 minutos), el plan gratuito resultaría insuficiente. El cambio es con el mismo proveedor, sin modificaciones técnicas:

Modelo	Precio (por millón)	Costo estimado S2*
GPT OSS 120B	u$d 0,15 + 0,60	~u$d 1,30/mes
GPT OSS 20B	u$d 0,075 + 0,30	~u$d 1,00/mes

*S2 = 30 consultas/día + vigilancia cada 15 min (supuesto). Señal para cambiar: avisos de cupo diarios reiterados. Alternativas descartadas con fundamento: LLM en servidor propio (costoso, sin datos que lo justifiquen) y alternativas gratuitas sin límites publicados o que utilizan los datos para entrenar.

Fuentes: consola Groq de la cuenta (límites y modelos de producción, 12/10/2026), docs Groq de precios y límites, mediciones propias en laboratorio con bitácora de auditoría. Precios en dólares. Supuestos de volumen a validar con el cliente antes de producción.