NOC Agent — Modelos de IA: comparativa y costos

Informe técnico para el cliente · 12 de octubre de 2026 · Piloto Etapa 1 (solo lectura)

1. Resumen ejecutivo

> El piloto completo (consultas diarias + vigilancia automática cada 15 minutos) funciona con el plan **gratuito** usando el modelo **GPT OSS 120B**, que fue el de mejor desempeño en las pruebas (6 de 8 tareas correctas). Costo del piloto: **u$d 0**. Los modelos pagos solo aparecen como camino de crecimiento: a los volúmenes estimados costarían entre **u$d 1 y u$d 8 por mes**, y solo se justifican si el uso supera el cupo gratuito.

2. Cómo funciona el servicio (gratis vs. pago)

El proveedor (Groq) ofrece los **mismos modelos en dos planes**:

- **Gratis:** sin tarjeta, con un cupo diario de uso (para el modelo elegido: 1.000 consultas y 200.000 fragmentos de texto por día). Verificado en la consola de la cuenta el 12/10/2026.
- **Pago:** mismos modelos, cupo ~10 veces mayor, se paga solo por lo consumido (desde u$d 1 acumulado, sin suscripción).

En criollo: es como una SUBE con viajes gratis limitados por día; si algún día se necesitan más viajes, se paga por cada uno a precio de centavos. **Nada de lo medido en este informe costó dinero.**

3. Tabla comparativa — modelos gratuitos

Modelo	Cupo gratis/día	Prueba (8 tareas)	A favor	En contra
GPT OSS 120B ⭐ elegido	1.000 consultas 200.000 textos	**6/8**	El más preciso: resolvió investigaciones que los demás no pudieron. Respuestas ordenadas, con datos reales.	Las tareas muy largas seguidas pueden esperar unos segundos (se resuelve con pausas automáticas).

Qwen 32B (reserva)	1.000 consultas 200.000 textos	3–4/8	Bueno en resúmenes simples. Alternativa si el titular no responde.	Falla en investigaciones paso a paso (no sigue el procedimiento).
GPT OSS 20B	1.000 consultas 200.000 textos	5/8	Más rápido. Investiga bien.	A veces repite la misma consulta en vez de variar; respuestas largas (gastan más). Segundo puesto.
Allam 7B	7.000 consultas 500.000 textos	**0/8 útiles**	Cupo generoso.	No sigue instrucciones: repite acciones y responde vaguedades. **Descartado.**

4. Qué se probó (números)

- **Chequeo básico del sistema (3/3):** conexión, lista de problemas activos, historial de un equipo y bloqueo correcto de una acción prohibida.
- **8 tareas reales por modelo** (resumir problemas, investigar un equipo, explicar por qué sonó una alarma, traer valores): resumen simple ≈ 1.300 textos; investigación completa ≈ 2.000–6.000.
- **Prueba de exigencia (10 consultas seguidas sin pausa):** 8 fueron frenadas por límite de velocidad. Con 60 segundos entre consultas: 5/5 correctas. Conclusión: el límite es de *velocidad por minuto*, no de cantidad diaria — el diseño final incluye pausas y reintentos automáticos.

5. El piloto entra en el plan gratuito (verificación)

Uso del piloto	Consumo/día	Cupo gratis	Margen
10 consultas de técnicos	~27.000 textos, ~30 consultas	200.000 / 1.000	**sobra**
Vigilancia cada 15 min	~125.000 textos, ~200 consultas	200.000 / 1.000	**entra**
Total piloto	**~150.000 / ~230**	200.000 / 1.000	**cubierto**

Volúmenes de uso supuestos a validar en operación (marcados como supuesto en la documentación de trabajo).

6. Modelos pagos: solo como crecimiento

Si el uso creciera (más equipos, vigilancia cada 5 minutos), el plan gratuito quedaría chico. El paso es el mismo proveedor, sin cambiar nada técnico:

Modelo	Precio (por millón)	Costo estimado S2*
GPT OSS 120B	u$d 0,15 + 0,60	~u$d 1,30/mes
GPT OSS 20B	u$d 0,075 + 0,30	~u$d 1,00/mes

*S2 = 30 consultas/día + vigilancia cada 15 min (supuesto). Señal para cambiar: avisos de cupo diarios reiterados. Descartado con motivo: LLM en servidor propio (costoso, sin datos que lo justifiquen) y alternativas gratuitas sin límites publicados o que usan los datos para entrenar.

Fuentes: consola Groq de la cuenta (límites y modelos de producción, 12/10/2026), docs Groq de precios y límites, mediciones propias en laboratorio con bitácora de auditoría. Precios en dólares. Supuestos de volumen a validar con el cliente antes de producción.