NOC Agent — Modelos de IA: comparativa y costos

Informe técnico para el cliente · 12 de octubre de 2026 · Piloto Etapa 1 (solo lectura)

1. Resumen ejecutivo

> El piloto completo (consultas diarias + vigilancia automática cada 15 minutos) funciona con el plan **gratuito** usando el modelo **GPT OSS 120B**, que fue el de mejor desempeño en las pruebas (6 de 8 tareas correctas). Costo del piloto: **u$d 0**. Los modelos pagos solo aparecen como camino de crecimiento: a los volúmenes estimados costarían entre **u$d 1 y u$d 2 por mes** con los modelos recomendados, y solo se justifican si el uso supera el cupo gratuito.

2. Cómo funciona el servicio (gratis vs. pago)

El proveedor (Groq) ofrece los **mismos modelos en dos planes**:

- **Gratis:** sin tarjeta, con un cupo diario de uso (para el modelo elegido: 1.000 consultas y 200.000 fragmentos de texto por día). Verificado en la consola de la cuenta el 12/10/2026.
- **Pago:** mismos modelos, cupo ~10 veces mayor, se paga solo por lo consumido (desde u$d 1 acumulado, sin suscripción).

Dicho de otro modo: el plan gratuito incluye una cuota diaria de uso sin costo; superada esa cuota, cada unidad adicional se factura a precio de costo, sin abonos ni mínimos. **Nada de lo medido en este informe generó cargo alguno.**

3. Tabla comparativa — modelos gratuitos

Modelo	Cupo gratis/día	Prueba (8 tareas)	A favor	En contra
GPT OSS 120B (recomendado)	1.000 consultas 200.000 textos	**6/8**	El más preciso: resolvió investigaciones que los demás no pudieron. Respuestas ordenadas, con datos reales.	Las tareas muy extensas consecutivas pueden requerir algunos segundos de espera (se compensa con pausas y reintentos automáticos).

Qwen 32B (reserva)	1.000 consultas 200.000 textos	3–4/8	Buen desempeño en resúmenes simples. Alternativa de respaldo ante indisponibilidad del modelo principal.	Presenta limitaciones en investigaciones paso a paso (no sigue el procedimiento).
GPT OSS 20B	1.000 consultas 200.000 textos	5/8	Mayor velocidad de respuesta. Buen desempeño en investigación.	En ocasiones repite la misma consulta en lugar de variar la estrategia; respuestas extensas (mayor consumo). Segunda opción.
Allam 7B	7.000 consultas 500.000 textos	**0/8 útiles**	Cupo diario superior.	No sigue instrucciones: repite acciones y responde con generalidades sin datos concretos. **Descartado.**

4. Qué se probó (números)

- **Verificación básica del sistema (3/3):** conexión, lista de problemas activos, historial de un equipo y bloqueo correcto de una acción prohibida.
- **8 tareas reales por modelo** (resumir problemas, investigar un equipo, explicar por qué se disparó una alarma, traer valores): resumen simple ≈ 1.300 textos; investigación completa ≈ 2.000–6.000.
- **Prueba de exigencia (10 consultas seguidas sin pausa):** 8 fueron limitadas por velocidad. Con 60 segundos entre consultas: 5/5 correctas. Conclusión: el límite es de *velocidad por minuto*, no de cantidad diaria — el diseño final incluye pausas y reintentos automáticos.

5. El piloto entra en el plan gratuito (verificación)

Uso del piloto	Consumo/día	Cupo gratis	Margen
10 consultas de técnicos	~27.000 textos, ~30 consultas	200.000 / 1.000	**sobra**
Vigilancia cada 15 min	~125.000 textos, ~200 consultas	200.000 / 1.000	**entra**
Total piloto	**~150.000 / ~230**	200.000 / 1.000	**cubierto**

Los volúmenes de uso son supuestos a validar en operación.

6. Modelos pagos: solo como crecimiento

Si el uso creciera (más equipos, vigilancia cada 5 minutos), el plan gratuito resultaría insuficiente. El cambio es con el mismo proveedor, sin modificaciones técnicas. Los precios se pagan solo por consumo, sin abonos (desde u$d 1 acumulado).

Modelo (mismo proveedor)	Precio (por millón)	Costo estimado S2*
GPT OSS 120B	u$d 0,15 + 0,60	~u$d 1,30/mes
GPT OSS 20B	u$d 0,075 + 0,30	~u$d 1,00/mes

*S2 = 30 consultas/día + vigilancia cada 15 min (supuesto).

7. Vía oficial: modelos de otros proveedores

Capacidades equivalentes están disponibles por vía oficial, con clave propia y contrato empresarial (planes pagos con términos que excluyen el uso de los datos para entrenamiento, según sus condiciones publicadas). No tienen plan gratuito: son alternativa de escala, no de piloto.

Modelo (vía oficial)	Precio (por millón)	Rol posible
Haiku (Anthropic)	u$d 0,05 + 0,25	Tareas simples y clasificación, al costo más bajo del mercado
GPT nano / mini (OpenAI)	u$d 0,05 + 0,40 / 0,25 + 2,00	Mismo esquema por niveles
Sonnet (Anthropic)	u$d 2,00 + 10,00	Investigación profunda de frontera, si la calidad lo exige

Calidad de estos modelos en este sistema: aún no medida (requiere el mismo protocolo de 8 tareas). Esquema recomendado a futuro: modelo económico para triage y clasificación, modelo superior solo para investigación compleja.

8. Proyección de costos por escenario (mensual, 30 días)

Volúmenes supuestos a validar en operación. Unidad de cálculo medida: resumen ≈ 1.300 textos, investigación ≈ 6.000, sesión de incidente completa ≈ 12.000.

Escenario	Plan gratuito	Pago 120B	Haiku (vía oficial)	Sonnet (vía oficial)
Piloto: 10 consultas/día	**u$d 0 (sobra)**	~u$d 0,20	~u$d 0,06	~u$d 2,40

Operación (S2): 30 consultas + vigilancia c/15 min	**u$d 0 (al límite)**	~u$d 1,30	~u$d 0,50	~u$d 19,60
Día de crisis (20 incidentes, por día)	**no entra (~365K vs 200K)**	~u$d 0,08	~u$d 0,03	~u$d 1,20

Lectura: el plan gratuito cubre el piloto y la operación normal; un día de crisis se absorbe con el plan pago por centavos ese día, o con diseño (capa determinista para lo repetitivo). Señal objetiva para subir de plan: avisos de cupo diarios reiterados. Quedaron descartados con fundamento: servidor propio (costoso, sin datos que lo justifiquen) y gratuitos sin límites publicados o que utilizan los datos para entrenar.

Fuentes: consola Groq de la cuenta (límites y modelos de producción, 12/10/2026), docs Groq de precios y límites, mediciones propias en laboratorio con bitácora de auditoría. Precios en dólares. Supuestos de volumen a validar con el cliente antes de producción.