NOC Agent — Modelos de IA: comparativa y costos

Informe técnico para el cliente · 12 de octubre de 2026 · Piloto Etapa 1 (solo lectura)

1. Resumen ejecutivo

> El piloto completo (consultas diarias + vigilancia automática cada 15 minutos) funciona con el plan **gratuito** usando el modelo **GPT OSS 120B**, que fue el de mejor desempeño en las pruebas (6 de 8 tareas correctas). Costo del piloto: **u$d 0**. Los modelos pagos solo aparecen como camino de crecimiento: a los volúmenes estimados costarían entre **u$d 1 y u$d 2 por mes** con los modelos recomendados, y solo se justifican si el uso supera el cupo gratuito.

2. Cómo funciona el servicio (gratis vs. pago)

El proveedor (Groq) ofrece los **mismos modelos en dos planes**:

- **Gratis:** sin tarjeta, con un cupo diario de uso (para el modelo elegido: 1.000 consultas y 200.000 fragmentos de texto por día). Verificado en la consola de la cuenta el 12/10/2026.
- **Pago:** mismos modelos, cupo ~10 veces mayor, se paga solo por lo consumido (desde u$d 1 acumulado, sin suscripción).

Dicho de otro modo: el plan gratuito incluye una cuota diaria de uso sin costo; superada esa cuota, cada unidad adicional se factura a precio de costo, sin abonos ni mínimos. **Nada de lo medido en este informe generó cargo alguno.**

3. Tabla comparativa — modelos gratuitos

Modelo	Cupo gratis/día	Prueba (8 tareas)	A favor	En contra
GPT OSS 120B (recomendado)	1.000 consultas 200.000 textos	**6/8**	El más preciso: resolvió investigaciones que los demás no pudieron. Respuestas ordenadas, con datos reales.	Las tareas muy extensas consecutivas pueden requerir algunos segundos de espera (se compensa con pausas y reintentos automáticos).

Qwen 32B (reserva)	1.000 consultas 200.000 textos	3–4/8	Buen desempeño en resúmenes simples. Alternativa de respaldo ante indisponibilidad del modelo principal.	Presenta limitaciones en investigaciones paso a paso (no sigue el procedimiento).
GPT OSS 20B	1.000 consultas 200.000 textos	5/8	Mayor velocidad de respuesta. Buen desempeño en investigación.	En ocasiones repite la misma consulta en lugar de variar la estrategia; respuestas extensas (mayor consumo). Segunda opción.
Allam 7B	7.000 consultas 500.000 textos	**0/8 útiles**	Cupo diario superior.	No sigue instrucciones: repite acciones y responde con generalidades sin datos concretos. **Descartado.**

4. Qué se probó (números)

- **Verificación básica del sistema (3/3):** conexión, lista de problemas activos, historial de un equipo y bloqueo correcto de una acción prohibida.
- **8 tareas reales por modelo** (resumir problemas, investigar un equipo, explicar por qué se disparó una alarma, traer valores): resumen simple ≈ 1.300 textos; investigación completa ≈ 2.000–6.000.
- **Prueba de exigencia (10 consultas seguidas sin pausa):** 8 fueron limitadas por velocidad. Con 60 segundos entre consultas: 5/5 correctas. Conclusión: el límite es de *velocidad por minuto*, no de cantidad diaria — el diseño final incluye pausas y reintentos automáticos.

5. El piloto entra en el plan gratuito (verificación)

Uso del piloto	Consumo/día	Cupo gratis	Margen
10 consultas de técnicos	~27.000 textos, ~30 consultas	200.000 / 1.000	**sobra**
Vigilancia cada 15 min	~125.000 textos, ~200 consultas	200.000 / 1.000	**entra**
Total piloto	**~150.000 / ~230**	200.000 / 1.000	**cubierto**

Los volúmenes de uso son supuestos a validar en operación.

6. Modelos pagos: solo como crecimiento

Si el uso creciera (más equipos, vigilancia cada 5 minutos), el plan gratuito resultaría insuficiente. El cambio es con el mismo proveedor, sin modificaciones técnicas. Los precios se pagan solo por consumo, sin abonos (desde u$d 1 acumulado).

Modelo (mismo proveedor)	Precio (por millón)	Costo estimado S2*
GPT OSS 120B	u$d 0,15 + 0,60	~u$d 1,30/mes
GPT OSS 20B	u$d 0,075 + 0,30	~u$d 1,00/mes

*S2 = 30 consultas/día + vigilancia cada 15 min (supuesto).

7. Vía oficial: modelos de otros proveedores

Los modelos de las suscripciones de desarrollo no pueden reutilizarse como motor del servicio (licencia de uso personal interactivo, sin clave para servidor propio ni auditoría). Sus capacidades equivalentes sí están disponibles por vía oficial, con clave propia y contrato empresarial (planes pagos con términos que excluyen el uso de los datos para entrenamiento, según sus condiciones publicadas). No tienen plan gratuito: son alternativa de escala, no de piloto.

Modelo (vía oficial)	Precio (por millón)	Rol posible
Haiku (Anthropic)	u$d 0,05 + 0,25	Tareas simples y clasificación, al costo más bajo del mercado
GPT nano / mini (OpenAI)	u$d 0,05 + 0,40 / 0,25 + 2,00	Mismo esquema por niveles
Sonnet (Anthropic)	u$d 2,00 + 10,00	Investigación profunda de frontera, si la calidad lo exige

Calidad de estos modelos en este sistema: aún no medida (requiere el mismo protocolo de 8 tareas). Esquema recomendado a futuro: modelo económico para triage y clasificación, modelo superior solo para investigación compleja.

8. Proyección de costos por escenario (mensual, 30 días)

Volúmenes supuestos a validar en operación. Unidad de cálculo medida: resumen ≈ 1.300 textos, investigación ≈ 6.000, sesión de incidente completa ≈ 12.000.

Escenario	Plan gratuito	Pago 120B	Haiku (vía oficial)	Sonnet (vía oficial)

Piloto: 10 consultas/día	**u$d 0 (sobra)**	~u$d 0,20	~u$d 0,06	~u$d 2,40
Operación (S2): 30 consultas + vigilancia c/15 min	**u$d 0 (al límite)**	~u$d 1,30	~u$d 0,50	~u$d 19,60
Día de crisis (20 incidentes, por día)	**no entra (~365K vs 200K)**	~u$d 0,08	~u$d 0,03	~u$d 1,20

Lectura: el plan gratuito cubre el piloto y la operación normal; un día de crisis se absorbe con el plan pago por centavos ese día, o con diseño (capa determinista para lo repetitivo). Señal objetiva para subir de plan: avisos de cupo diarios reiterados. Quedaron descartados con fundamento: servidor propio (costoso, sin datos que lo justifiquen) y gratuitos sin límites publicados o que utilizan los datos para entrenar.

Fuentes: consola Groq de la cuenta (límites y modelos de producción, 12/10/2026), docs Groq de precios y límites, mediciones propias en laboratorio con bitácora de auditoría. Precios en dólares. Supuestos de volumen a validar con el cliente antes de producción.